Documentação – Dicovery de Produto

Mapeamento de negócios, jornada e esteira de atuação

Projeto de IA generativa – Áudio e Vídeo

PM Jessé Oliveira de Castro

1. Governança
   1.1 Versão e Histórico de alterações
   1.2 Aprovadores
2. Visão de produto
   2.1 Contexto do problema (a dor que resolveremos)
   2.2 Objetivo e OKR associado
   2.3 Stakeholders: Pontos Focais e Matriz de responsabilidades
3. Definição de negócio e UX
   3.1 Glossário de métricas
   3.2 Racional das métricas e visões: Matemáticas, fórmulas, métricas, regras do negócio
   3.3 Regras de negócios e Filtros: Visões, base modelar
   3.4 User Journey (como o usuário chega ao dado)
   3.5 Mockups previstos (telas)
   3.6 Público alvo: Frequência e audiência do E-mail (se automático)
4. Arquitetura técnica e Engenharia
   4.1 Mapeamento de dados e Ingestão
      4.1.1 Bases e Paths internos: Tabelas, consultas, Imputs manuais, relatórios paralelos
      4.1.2 Fontes Externas:
      4.1.3 Qualidade do dado: Regras de validação e saneamento de dados
   4.2 Processamento
      4.2.1 Mapeamento Notebooks
      4.2.2 Detalhamento Notebooks
      4.2.3 Pipelines
      4.2.4 Triggers e expectativa da frequência de atualização
   4.3 AAS, Dataflow, modelo de dados
      4.3.1 Arquitetura de fatos e dimensões
      4.3.2 Modelo de servidor
5. Segurança e compliance (LGPD)
   5.1 Classificação de dados (Sensíveis/Pessoais)
   5.2 Regras de Acesso e mascaramento
6. Gestão do projeto
   6.1 Cronograma macro e MilesTone (marcos de entregas)
   6.2 Riscos identificados e planos de mitigação
   6.3 Dependências
7. Sustentação
   7.1 Critérios de aceite (Definition of Done)
   7.2 Plano Roll-out (Lançamento e comunicação)
   7.3 Modelo de sustentação (Quem suporta? SLA? Logs)
8. Documentação das mudanças solicitadas no percurso

1. Governança

1.1. Versão e histórico de alterações

Versionamento	Data	Responsável	Descrição
1.0	25/02/2026	Jesse-DataDriven	1ª Versão - Discovery IA Generativa Voz e Vídeo

Histórico de alterações: Não há histórico por ser um projeto novo (do zero)

Histórico de alterações:

25/02/2026: Criada V1 (Discovery inicial a partir dos notebooks). Responsável: Jesse. Status: Em análise

1.2 Aprovadores

Nome: Jessé Oliveira

Área: Desenvolvedor e PM

Cargo: Desenvolvedor e PM

2. Visão de Produto

Este documento tem por objetivo explanar as informações e procedimentos adotados pelo time de ABC, para a criação do produto XPTO. A documentação visa, garantir consolidação de todas as informações necessárias para as etapas da construção do projeto e também melhor entendimento das necessidades desde a largada, facilitando a manutenção e compreensão das técnicas ou métricas utilizadas pelo stakeholder, registros, alinhamentos e desafios oriundos das cerimônias de trabalho do projeto, além de facilitação e aceleração de desenvolvimento por meio de metodologia Agile.

- **2.1 Contexto do problema (a dor que resolveremos)**

  Problema: O objetivo principal é acadêmico. Aprender a criar, codar, automatizar modelos de IA desde a estruturação em uma habilidade específica de IA atualmente que é criar vídeos com lip-sync sincronizado e clonagem de voz para múltiplos idiomas sem necessidade de re-gravação

- **Dor: Não entender 100% do funcionamento do mecanismo generativo no backend.**

- **Solução: Pipeline criando e automatizado IA Generativa para clonagem de voz + sincronização labial automática**

2.2 Objetivo e OKR associado

O projeto deve contribuir com o aprendizado. Meta: 100% de entendimento do backend da IA generativa.

2.3 Stakeholders: Jessé Oliveira

3. Definição de negócio e UX

3.1 Glossário de métricas

Métrica	Descrição
1. Tempo de Processamento	Tempo total para gerar vídeo com lip-sync
2. Qualidade de Áudio	Fidelity da voz clonada vs original
3. Sincronização Labial	Precisão do lip-sync (WER/LER)
4. Tempo de Inferência	Tempo de processamento do modelo LatentSync
5. Uso de GPU	Memória e tempo de GPU consumido
6. Taxa de Sucesso	% de vídeos gerados sem erro

3.2 Racional das métricas e visões: Matemáticas, fórmulas, métricas, regras do negócio

Tempo Total = Extração Áudio + Tradução + TTS + Lip-Sync + Merge

Qualidade Áudio = Similaridade voz clonada vs original

Sincronização = WER (Word Error Rate) do áudio vs movimento labial

3.3 Regras de negócios e Filtros: Visões, base modelar}

Vídeo input: Formato MP4, resolução mínima 720p (identificado no notebook: 1280x720)

Áudio: Sample rate 48000 Hz, stereo

Modelo TTS: XTTS v2 (multilíngue): O **XTTS** (eXtensible Text-to-Speech) é o modelo mais aderente ao projeto e à estrutura proposta. Este modelo será o responsável pela clonagem da voz no treinamento. Basicamente ele gerará o WaV para o prompt que gerarei.

Modelo Lip-Sync: LatentSync UNet (stage1): Pré-treino – o modelo aprende a construir o rosto de forma estática e genérica.

Modelo Lip-Sync: LatentSync UNet (stage2): Aqui acontece a efetiva sincronização do que foi gerado no XTTS e ensina a colocar no rosto treinado no stage 1 a encaixar exatamente as expressões.

Modelo Audio: Whisper Tiny

Filtros necessários:

Tentar criar variável prefix no python para acurar o prompt gatilho

Confirmador de Prompt positivo: masterpiece, best quality, highly detailed, sharp focus.

Confirmador de prompt negativo: ugly, deformed, noisy, blurry, distorted, out of focus, bad anatomy, extra limbs, poorly drawn face, poorly drawn hands, missing fingers

3.4 User Journey (como o usuário chega ao dado)

O projeto tem premissa open source. A tentativa é hospedar no github ou deploy no netlify

3.5 Mockups previstos (telas)

Visão 1: Tela minimalista a exemplo de IA's de mercado

3.6 Público alvo: Frequência e audiência do E-mail (se automático)

Projeto de cunho acadêmico e de formação.

4. Arquitetura técnica e Engenharia

4.1 Mapeamento de dados e Ingestão

4.1.1 Bases e Paths internos: Tabelas, consultas, Imputs manuais, relatórios paralelos

Tipo	Descrição	Path/Local
Vídeo Input	Arquivo MP4 original	Google Drive: `/content/drive/MyDrive/video-clone-pipeline/`
Áudio Input	Arquivo WAV extraído	Google Drive: `/content/drive/MyDrive/video-clone-pipeline/`
Áudio Output	Áudio gerado com voz clonada	Google Drive: `/content/drive/MyDrive/video-clone-pipeline/`
Vídeo Output	Vídeo final com lip-sync	Google Drive: `/content/drive/MyDrive/video-clone-pipeline/`
Checkpoints	Modelos de IA	`/content/LatentSync/checkpoints/`

4.1.2 Fontes Externas:

Fonte	Tipo	Uso
Hugging Face	Modelo LatentSync UNet	`https://huggingface.co/ByteDance/LatentSync/resolve/main/latentsync_unet.pt`
Azure/OpenAI	Modelo Whisper Tiny	`https://openaipublic.azureedge.net/main/whisper/models/`
Coqui AI	Modelo XTTS v2	TTS Models (multilingual)
Google Translate	API Tradução	Deep Translator library

4.1.3 Qualidade do dado: Regras de validação e saneamento de dados

Validação	Regra
Formato Vídeo	MP4, H.264 codec
Resolução Mínima	720p (1280x720 identificado)
Sample Rate Áudio	48000 Hz
Channels	Stereo
Duração Vídeo	JESSÉ VERIFICAR MANUALMENTE (teste com 10s e 2min11s identificados)
Tamanho Máximo GPU	JESSÉ VERIFICAR MANUALMENTE (T4 GPU identificada)

4.2 Processamento

4.2.1 Mapeamento Notebooks

Notebook	Função	Status
IA Generativa voz e vídeo.ipynb	Pipeline completo: TTS + Lip-Sync	Em produção (Colab)

4.2.2 Detalhamento Notebooks

IA Generativa voz e vídeo.ipynb:

Etapa	Tecnologia	Descrição
1. Setup	Git, pip	Clone repositórios, install dependencies
2. Extração Áudio	FFmpeg	Extrair áudio do vídeo original
3. Voice Cloning	Coqui TTS (XTTS v2)	Clonar voz do speaker original
4. Tradução	Deep Translator (Google)	Traduzir script para idioma alvo
5. TTS Generation	Coqui TTS	Gerar áudio com voz clonada no idioma alvo
6. Lip-Sync	LatentSync	Sincronizar movimento labial com novo áudio
7. Merge Final	FFmpeg	Combinar vídeo + áudio sincronizado
8. Save Output	Google Drive	Salvar resultado final

4.2.3 Pipelines

```
┌──────────┐    ┌──────────┐    ┌──────────┐
│ Vídeo    │──▶│ Extração │──▶│ Áudio    │
│ Original │    │ FFmpeg   │    │ Original │
└──────────┘    └──────────┘    └──────────┘
                                     │
                                     ▼
┌──────────┐    ┌──────────┐    ┌──────────┐
│ Vídeo    │◀──│ Lip-Sync │◀──│ Áudio    │
│ Final    │    │ LatentSync│    │ Clonado  │
└──────────┘    └──────────┘    └──────────┘
                     ▲
                     │
                ┌──────────┐
                │ Tradução │
                │ + TTS    │
                └──────────┘
```

4.2.4 Triggers e expectativa da frequência de atualização

Trigger	Frequência	Responsável
Execução Notebook	Manual (Colab)	JESSÉ VERIFICAR MANUALMENTE
Download Modelos	One-time setup	Automático
Save Output	Por execução	Automático (Drive)

4.3 AAS, Dataflow, modelo de dados

4.3.1 Arquitetura de fatos e dimensões

Tipo	Entidade	Atributos
Fato	Execução Pipeline	Data, Tempo, Status, Idioma
Dimensão	Vídeo Input	Duração, Resolução, Formato
Dimensão	Áudio Output	Duração, Sample Rate, Idioma
Dimensão	Modelo	Versão, Tipo, Fonte

4.3.2 Modelo de servidor

Componente	Infraestrutura	Configuração
Runtime	Google Colab	GPU T4 (identificado no notebook)
Storage	Google Drive	`/content/drive/MyDrive/video-clone-pipeline/`
Version Control	GitHub	`https://github.com/Jesse-DataDriven/IA-Lab-Jesse`
Models	Hugging Face + Azure	LatentSync, Whisper, XTTS

5. Segurança e compliance (LGPD)

5.1 Classificação de dados (Sensíveis/Pessoais)

Não haverá restrições nessa fase do projeto.

5.2 Regras de Acessso e mascaramento

Os ID’s únicos de conexão (Github, GoogleDrive, Ngrok) foram suprimidos.

6. Gestão do projeto

6.1 Cronograma macro e MilesTone (marcos de entregas)

Milestone	Data Prevista	Status
M1: Setup Ambiente	25/02/2026	✅ Concluído (Colab)
M2: Pipeline TTS	25/02/2026	✅ Concluído
M3: Pipeline Lip-Sync	25/02/2026	🔄 Em teste (LatentSync)

6.2 Riscos identificados e planos de mitigação

Risco	Impacto	Probabilidade	Mitigação
GPU Memory Overflow (LatentSync)	Alto	Alto	Otimizar vídeo input, usar vídeos curtos para teste
Modelo LatentSync não carrega	Alto	Médio	Verificar compatibilidade de versões (Diffusers, PyTorch)
Qualidade de Lip-Sync inadequada	Médio	Médio	Ajustar parâmetros do modelo, testar stage1 vs stage2
Tempo de Inferência elevado	Médio	Alto	Otimizar batch size, usar GPU mais potente

6.3 Dependências

Dependência	Tipo	Status
Google Colab GPU	Infraestrutura	Disponível (T4)
Hugging Face	Modelo	Disponível (LatentSync)
Azure/OpenAI	Modelo	Disponível (Whisper)
Coqui TTS	Modelo	Disponível (XTTS v2)
JESSÉ VERIFICAR MANUALMENTE	JESSÉ VERIFICAR MANUALMENTE	JESSÉ VERIFICAR MANUALMENTE

7. Sustentação

7.1 Critérios de aceite (Definition of Done)

Critério	Descrição	Status
Pipeline executa sem erro	Notebook roda do início ao fim	🔄 Testando
Lip-Sync sincronizado	Áudio e vídeo sincronizados	🔄 Testando
Voz clonada fiel	Similaridade com voz original	🔄 Testando
Output salvo no Drive	Arquivo disponível no Drive	✅ Concluído

7.2 Plano Roll-out (Lançamento e comunicação)

Apenas compartilhar com a rede os dados: Volume de ensaios, volume de processamento, vídeos produzidos, aprendizagens.

7.3 Modelo de sustentação (Quem suporta? SLA? Logs)

Jessé Oliveira de castro

8. Documentação das mudanças solicitadas no percurso

Stack Tecnológico

Categoria	Tecnologia	Versão
Linguagem	Python	3.12 (Colab)
TTS	Coqui TTS	XTTS v2
Lip-Sync	LatentSync	ByteDance (stage2)
Audio Recognition	Whisper	Tiny
Tradução	Deep Translator	Google Translate
Vídeo Processing	FFmpeg	4.4.2
Deep Learning	PyTorch	JESSÉ VERIFICAR MANUALMENTE
Diffusion	Diffusers	JESSÉ VERIFICAR MANUALMENTE
Cloud	Google Colab	GPU T4
Storage	Google Drive	-
Version Control	GitHub	Jesse-DataDriven/IA-Lab-Jesse

Models Downloaded

Modelo	Tamanho	Path
latentsync_unet.pt	3.2 GB	`/content/LatentSync/checkpoints/`
whisper/tiny.pt	72 MB	`/content/LatentSync/checkpoints/whisper/`
XTTS v2	Download automático	Coqui TTS API

Models Downloaded

Modelo	Tamanho	Path
latentsync_unet.pt	3.2 GB	`/content/LatentSync/checkpoints/`
whisper/tiny.pt	72 MB	`/content/LatentSync/checkpoints/whisper/`
XTTS v2	Download automático	Coqui TTS API

Comandos Críticos Identificados

bash

```bash
# Clone LatentSync
git clone https://github.com/bytedance/LatentSync.git

# Download modelos
wget -O checkpoints/latentsync_unet.pt "https://huggingface.co/Bytel
wget -O checkpoints/whisper/tiny.pt "https://openaipublic.azureedge

# Inferência
python scripts/inference.py --unet_config_path "configs/unet/stage2
```

Documento gerado em: 25/02/2026

Responsável: Jesse-DataDriven

Status: V1.0 - Em análise